

Name des Studierenden: Cermak Marius

Exposé – Masterthesis

Arbeitstitel

Optimierung des Energieeinsatzes eines Bürogebäudes durch Anwendung einer Model Predictive Control Regelung der Kältemaschinen auf Basis von historischen Messdaten

Zusammenfassung des Themas – Hintergrund – Relevanz des Themas

Ein angemessenes Management des Energiebedarfs von Gebäuden ist eine Herausforderung für Facility Manager. Die richtige Nutzung der Energie in einem Gebäude führt nicht nur zu geringerem Energiebedarf, sondern auch zu geringeren Betriebskosten des Gebäudes. Wenn die Gebäudeverwaltung das Energiebedarfsprofil des Gebäudes prognostizieren könnte, kann dies zur Senkung des Energiebedarfs des Gebäudes führen. Bei in Wien untersuchten Bürogebäuden ergab sich, dass der tatsächliche Kältebedarf um rund 39 % höher ist als im Energieausweis angegeben (Bayer et al. 2014).

Es besteht also Potenzial bei der Verringerung des Kältebedarfs bei Bestandsgebäuden. Um den Kältebedarf zu senken bzw. die eingesetzten Erzeugungsgeräte effizienter zu betreiben, sind Prognosen der Last unabdingbar. Dies kann mithilfe von Simulationsmodellen (z.B. digitaler Zwilling) in diversen kommerziellen Programmen (IDA ICE, TRNSYS, ESP-r) realisiert werden. Solche Simulationsmodelle benötigen jedoch genaue Angaben zur Gebäudehülle sowie Nutzung, um vergleichbare Ergebnisse zu liefern.

Die Entwicklung der Technologien wie Sensoren, drahtlose Übertragung und Netzwerkkommunikation hat zu einer steigenden Datenmenge in Bestandsgebäuden geführt. Wenn genügen Messdaten (Frequenz/Beobachtungen/Dichte) vorhanden sind, bieten Simulationsmodelle, die auf Machine Learning basieren, diverse Vorteile. Die Entwicklungszeit, Simulationszeit sowie die Genauigkeit der Prognose sind je nach Datenqualität vergleichbar oder besser als herkömmliche Simulationsmodelle (Tien et al. 2022).

In den letzten Jahren hat die Anwendung von Model Predictive Control (MPC) für das Energiemanagement in Gebäuden große Beachtung gefunden. MPC werden praktikabler, da die Rechenleistung von Gebäudeautomationssystemen zunimmt und eine große Menge an Gebäudedaten verfügbar ist. MPC bieten mehrere Möglichkeiten zur Verbesserung der Energieeffizienz beim Betrieb von HLK-Anlagen, da sie in der Lage ist, Einschränkungen, die Vorhersage von Störungen und mehrere widersprüchliche Ziele, wie den Wärmekomfort in Innenräumen und den Energiebedarf des Gebäudes, zu berücksichtigen (Serale et al. 2018).

Ziel der Arbeit – („was ist nachher anders“)**Hauptziele:**

Es soll ein Modell gebildet werden, mit dem der Kältebedarf eines Bürogebäudes, auf Basis von Klimadaten (Temperatur, Luftfeuchtigkeit, Sonnenstrahlung) und historischen Messdaten (Vorlauf/Rücklauf Temperatur, Volumenstrom, CO₂ Gehalt der Luft, Rauminnentemperatur), prognostiziert werden kann. Der angestrebte Zeithorizont des Prognosemodells liegt bei 24 Stunden. Aufbauend auf dem Prognosemodell soll eine Model Predictive Control Regelung implementiert und mit der bestehenden Regelung verglichen werden.

Nebenziele:

Es soll eine Abschätzung der benötigten Beobachtungen sowie des benötigten Datenzeitraumes erstellt werden. Ebenso soll eine Bewertung unterschiedlicher Machine Learning Ansätze für die Prognose des Kältebedarfs erstellt werden.

Konkrete wissenschaftliche Fragestellung

Wie viel Energieeinsparung kann, im Vergleich zur bestehenden Regelung, durch eine Model Predictive Control Regelung der Kältemaschinen eines Bürogebäudes erzielt werden?

Wichtigste Grundlagenliteratur – Forschungsstand – Abgrenzung zu ähnlichen Fragestellungen

Wichtigste Grundlagenliteratur:

Für die Prognose des Energiebedarfes in Gebäuden werden verschiedene Machine Learning Ansätze eingesetzt (Support Vector Machine, Artificial Neural Networks, Gaussian Process). Es kann jedoch keine generelle Aussage darüber getroffen werden, welcher Ansatz sich am besten zur Prognose des Energieverbrauches eignet. Mit ausreichender Datenmenge und Optimierung der Feature Auswahl bietet jeder Ansatz eine akzeptable Präzision der Prognose (Seyedzadeh et al. 2018).

Machine Learning wird für die Prognose des Energiebedarfes im Gebäudebereich verwendet. Im Vergleich zu herkömmlichen Simulationsmodellen zeigen sich in der Entwicklungszeit sowie in der Menge der benötigten Informationen zum Gebäude (z.B. Gebäudehülle, Regelstrategien) Vorteile. Dabei kommen viele verschiedene Ansätze, z.B. Supervised/Unsupervised Learning sowie Reinforcement Learning zum Einsatz. Aufgrund der Vielzahl der Ansätze und Prüfmethoden der Ansätze, befindet sich dieses Forschungsfeld noch im experimentellen Stand. Auch werden die Ergebnisse dieser Studien nur bedingt in realen Gebäuden eingesetzt. Dadurch besteht noch zusätzlicher Bedarf an Studien. Der richtige Ansatz hängt dabei von der Datenverfügbarkeit, Praktikabilität sowie dem Berechnungsaufwand des Modells ab. Für Energieverbrauchsprognosen lässt sich jedoch ein Trend in Richtung Deep Reinforcement Learning für kurzzeitige (Zeithorizont von 24h) Prognosen beobachten (Tien et al. 2022).

Model Predictive Control (MPC) ist eine Strategie zur Steuerung von Gebäuden oder HLK-Anlagen, bei der die optimalen Steuereingänge, durch Minimierung einer vorgegebenen Zielfunktion, über einen gegebenen Prognosehorizont berechnet werden. Das Modell des Systems wird mit aktuellen Zustandsmessungen und der Wettervorhersage verwendet, um das zukünftige Verhalten des Gebäudes zu prognostizieren. MPC können bekannte zukünftige Ereignisse, Störungen und Änderungen von Sollgrößen berücksichtigen. In den meisten Anwendungen von MPC können diese Energieeinsparungen von 10-30 % im Vergleich zu bestehenden Regelungen vorweisen (Seralle et al. 2018).

MPC für den Gebäudebetrieb können auf verschiedene Arten umgesetzt werden. Die zu minimierende Zielfunktion kann verschiedene Ziele haben, wobei die Komfortmaximierung sowie die Kostenminimierung am meisten Anwendung finden. Das Gebäudemodell, welches dem Controller zugrunde liegt, kann verschieden aufgebaut sein. So gibt es „White Box“ Modelle, bei denen das Verhalten des Gebäudes durch klar definierte, physikalische Vorgänge bestimmt wird. Darunter fallen gängige Simulationsprogramme wie IDA-ICE, TRNSYS und ESP-r. Bei „Gray Box“ Modellen werden die physikalischen Formeln durch Linearisierung vereinfacht. Diese Modelle werden als sogenannte RC-Modelle realisiert. Bei „Black Box“ Modellen wird das Verhalten des Gebäudes durch Messdaten, ohne zugrunde legen von physikalischen Formeln, durch Machine Learning erlernt. Je nach Problemklasse der Zielfunktion (Linear, Nichtlinear, Hybrid) kommen verschiedene Lösungstechniken (Implizit, Explizit, Ungefähr) zum Einsatz. Die Unstimmigkeit zwischen Modell und realer Anlage muss ebenfalls berücksichtigt werden zur Steigerung der Leistungsfähigkeit von MPC (Drgoňa et al. 2020).

Um HLK-Systeme in Gebäuden zu steuern und regeln, gibt es verschiedene Methoden. Diese Methoden können grundsätzlich in vier verschiedene Kategorien geteilt werden:

- Conventional control: Manual/On-Off, Feedback, Feed-forward, Bang-Bang, P, PI, PID
- Rule-based control: Gain Scheduling, State-Space Multivariable, Transfer Function Method, Self-Tuning Controller, Nonlinear Controller
- Hybrid, soft-computing control: Artificial Intelligence, Fuzzy Logic, Genetic Algorithm, Nonlinear Hybrid, Data-Driven Control
- Advanced control: MPC, Robust MPC, Optimal Control, Stochastic MPC, Adaptive Control (Drgoňa et al. 2020)

Forschungsstand:

Fehlende oder fehlerhafte Daten führen zu ungenauen Vorhersagen vom Kältebedarf von Gebäuden. Um dies zu bereinigen werden fehlende Daten mit dem k-Nearest-Neighbour (KNN) Algorithmus ersetzt. Ausreißer/Extremwerte in den Daten werden mithilfe der 3-Sigma Methode gefunden und ersetzt. Um die Abhängigkeit der Anwesenheit von Personen auf den Kühlbedarf darzustellen, werden zeitliche und klimatische Features getrennt analysiert. Die Prognose selbst wird mit dem LightGBM Algorithmus durchgeführt. Mit diesen Optimierungen der Daten wird eine Steigerung der Prognosegenauigkeit von 62 % auf 96 % erreicht (Zhao et al. 2022).

Der Kühlbedarf von Gebäuden wird mit einem Recurrent Neural Network (RNN) prognostiziert. Um die Prognosegenauigkeit bei langen Inputsequenzen zu erhöhen wird ein Aufmerksamkeitsmechanismus bei der Gewichtung der Neuronen hinzugefügt. Durch diesen Aufmerksamkeitsmechanismus wird ebenso die Interpretierbarkeit des Modells gesteigert (Li et al. 2021).

Für bestehende Gebäude bieten White Box Simulationsmodelle eine gute Grundlage für die Prognose des Gebäudebedarfs. Solche Modelle erfordern jedoch ausführliche Informationen über die Parameter des Gebäudemodells und leiden oft unter Bias. Als Alternative wird ein datengesteuerter Ansatz zur Prognose der Kühllast für 3 Bildungsgebäude in Arizona vorgeschlagen (Black Box Modell). Als Inputdaten werden Mikroklimadaten herangezogen, die mit der Software ENVI-met simuliert wurden. Dabei kommen verschiedene Machine Learning Algorithmen zum Einsatz (Random Forest, XGBoost, LightGBM und CatBoost). Der Random Forest Algorithmus erzielt die höchsten Prognosegenauigkeiten mit einem R^2 Wert von 0.98 (Alyakoob et al. 2023).

Für die kurzzeitige Energieverbrauchsprognose mit Deep Recurrent Neural Networks eignen sich grundsätzlich mehrere Ansätze, die jeweils eigene Charakteristika besitzen. Eine Kombination mit Gated Recurrent Unit (GRU) als Gating-Mechanismus hat dabei höhere Prognosegenauigkeiten erzielt, im Vergleich zu Long-Short-Term.Memory (LSTM) Ansatz und konventionellen Recurrent Neural Networks (RNN) (Fan et al. 2019).

Komplexe MPC stellen immer höhere Anforderungen an Hardware und Software zusammen mit komplizierteren Möglichkeiten der Fehlerbehandlung. Ein Machine Learning gestützter Ansatz kann Abhilfe schaffen. Die Idee basiert auf der Entwicklung von vereinfachten Steuergesetzen, die von der MPC gelernt werden. Der Ansatz verwendet multivariate Regressionsalgorithmen und verringert die Dimensionalität des Modells auf die wichtigsten Einflussgrößen. Die Ergebnisse zeigen, dass dieser Ansatz die Leistung der komplexen MPC größtenteils beibehaltet und gleichzeitig die Komplexität und den Implementierungsaufwand erheblich verringert (Drgoňa et al. 2018).

Abgrenzung zu ähnlichen Fragestellungen:

Um den Energieverbrauch und damit die Kosten zu senken wird ein MPC in einem Bürogebäude eingesetzt. Dabei kommen Einschränkungen in Form von Komfort und Bauteilgrenzen zum Einsatz. Der Betrieb der Fußbodenheizung/-kühlung wird mithilfe eines „Gray Box“ Modells gesteuert. Im Vergleich zur bestehenden Regelung (baseline Feedback Control) kann eine Kostenreduktion von 34 % in der Kühltisaison und eine Energieeinsparung von 16 % in der Heizsaison erzielt werden (Joe and Karava 2019).

Unterschiede zu dieser Arbeit:

- Verwendung eines Black Box Modells
- Nur Betrachtung der Kühltisaison
- Keine wirtschaftliche Betrachtung

Um den Kälteverbrauch in einem Bürogebäude in Singapur zu senken, wird ein adaptiver MPC für die Lüftungsanlage eingesetzt. Die Prognose stützt sich dabei auf ein Black Box Modell, welches mit einem Artificial Neural Network realisiert wird. Es kann eine Reduktion des Kältebedarfes von 58,5 % und eine Komfortsteigerung erzielt werden (Yang et al. 2020).

Unterschiede zu dieser Arbeit:

- Mit dem MPC werden die Kältemaschinen gesteuert
- Anderes Klima
- Keine genaue Betrachtung des Komforts

In einer Studie in Süditalien wird die Auswirkung eines MPC auf den Kühlbedarf eines nahezu Null-Energiegebäudes, unter Berücksichtigung von verschiedenen Komfortmodellen (ASHRAE/Fanger), untersucht. Dabei kam ein White Box Modell zur Anwendung. Verglichen mit einem fixen Sollwert bei 26 °C, kann eine Energieeinsparung von ca. 28 % erreicht werden, unter ähnlichen Komfortwerten (Ascione et al. 2023).

Unterschiede zu dieser Arbeit:

- Verwendung eines Black Box Modells
- Keine Sensitivitätsanalyse von verschiedenen Komfortmodellen

Einzusetzende wissenschaftliche Methoden – Begründung für deren Eignung, die Frage zu beantworten

Einzusetzende wissenschaftliche Methoden:

Literaturrecherche:

- Eingrenzung von Publikationen der letzten 6 Jahre
- Keywords: building energy consumption forecasting, MPC in HVAC
- Datenbanken/Suchmaschinen: Science Direct, Google Scholar, Springer

Aufbereitung der Messdaten:

- Programmiergestützt mit Python
- Bereinigung und Prüfung der Datensätze (Ersetzen von fehlenden/fehlerhaften Datensätzen)
- Feature Engineering zur Erhöhung der Prognosegenauigkeit (z.B. Time Series Shifting)

Training/Validierung des Modells:

- Mit externen Libraries in der Programmiersprache Python
- Auswahl der wichtigsten Features auf Basis der Korrelation
- Bewertung der Machine Learning Ansätze auf folgende Kennwerte:
 - Coefficient of Variance (CV)
 - Mean Bias Error (MBE)
 - Mean Squared Error (MSE)
 - Root Mean Squared Error (RMSE)
 - Mean Absolute Error (MAE)
- Auswahl des geeigneten Ansatzes nach Kennwerten

Sensitivitätsanalyse des verwendeten Ansatzes:

- Variierung des Ansatzes auf benötigte Daten, hidden Layer, Zeitintervalle der Messdaten, verwendete Features

Erstellung des MPC:

- Problemklasse des MPC aufgrund des nichtlinearen ML-Modells ebenfalls nichtlinear
- Aufbauend auf einem Black Box Modell

Bewertung des MPC und dem bestehenden Algorithmus auf verschiedene Vergleichsgrößen

- Kosten-, Ressourcen- und Energieeinsparungen
- Übertragung von Spitzenlasten
- Verbesserte Regelung und geringere Abweichung von den Sollwerten
- Verbesserung Luftqualität und des thermischen Komforts

Begründung für deren Eignung, die Frage zu beantworten:

Die Eingrenzung der Publikationen auf die letzten 6 Jahre sorgt dafür, dass nur aktuelle und relevante Informationen berücksichtigt werden. Die Aufbereitung der Messdaten ist ein wichtiger Schritt, um ein möglichst genaues und verlässliches Modell zu entwickeln. Durch die Bereinigung und Prüfung der Datensätze werden fehlerhafte oder fehlende Werte entfernt oder ersetzt, was die Qualität der Daten erhöht. Das Feature Engineering bezieht sich auf die Auswahl und Transformation von Merkmalen (Features), die für das Modell wichtig sind. Python wird in der wissenschaftlichen Arbeit häufig als Programmiersprache eingesetzt, da es eine flexible Sprache ist, die viele Funktionen und Bibliotheken für die Datenanalyse und das Machine Learning bereitstellt.

Das Training und die Validierung des Modells dienen dazu, das Modell anhand von bekannten Daten zu optimieren und zu bewerten. Hierfür werden externe Libraries in Python verwendet. Anschließend werden verschiedene Machine Learning Ansätze auf ihre Leistungsfähigkeit hin evaluiert, indem verschiedene Kennwerte berechnet werden. Der geeignete Ansatz wird anhand dieser Kennwerte ausgewählt.

Die Sensitivitätsanalyse dient dazu, die Robustheit des verwendeten Ansatzes zu untersuchen. Dazu werden verschiedene Parameter variiert und die Auswirkungen auf die Prognosegenauigkeit gemessen.

Die Bewertung des MPC und des bestehenden Algorithmus erfolgt anhand verschiedener Vergleichsgrößen, um die Leistungsfähigkeit und den Nutzen des MPC im Vergleich zu etablierten Verfahren zu beurteilen.

Inhaltsstruktur – Forschungsschritte

Inhaltsstruktur

- Einleitung
 - Motivation
 - Forschungsfrage
- Methode
- Prognosemodell
 - Theorie
 - Aufbereitung Messdaten
 - Feature Engineering
 - Ergebnisse der Kennwerte
 - Sensitivitätsanalyse des ausgewählten Ansatzes
- Model Predictive Control
 - Theorie
 - Erstellung der Zielfunktion
 - Ergebnisse des MPC
- Interpretation der Ergebnisse

Ev. Zeitplan

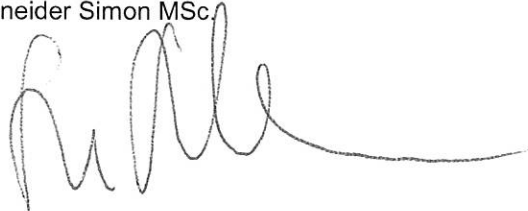
Ev. Literaturliste

- Abida, A., Richter, P., 2022, HVAC control in buildings using neural network. Journal of Building Engineering; 105558
- Alyakoob, A., Hartono, S., Johnson, T., Middel, A., 2023, Estimating cooling loads of Arizona State University buildings using microclimate data and machine learning. Journal of Building Engineering, Volume 64, Number; 105705
- Ascione, F., De Masi, R.F., Festa, V., Mauro, G.M., Vanoli, G.P., 2023, Optimizing space cooling of a nearly zero energy building via model predictive control: Energy cost vs comfort. Energy and Buildings, Volume 278, Number; 112664
- Bayer, G., Sturm, T., Steininger, M., 2014, Energieflüsse in Bürogebäuden - (NEWID – IST).
- Drgoňa, J., Arroyo, J., Cupeiro Figueroa, I., Blum, D., Arendt, K., Kim, D., Ollé, E.P., Oravec, J., Wetter, M., Vrabie, D.L., Helsen, L., 2020, All you need to know about model predictive control for buildings. Annual Reviews in Control, Volume 50, Number; 190–232
- Drgoňa, J., Picard, D., Kvasnica, M., Helsen, L., 2018, Approximate model predictive building control via machine learning. Applied Energy, Volume 218, Number; 199–216
- Fan, C., Wang, J., Gang, W., Li, S., 2019, Assessment of deep recurrent neural network-based strategies for short-term building energy predictions. Applied Energy, Volume 236, Number; 700–710

- Joe, J., Karava, P., 2019, A model predictive control strategy to optimize the performance of radiant floor heating and cooling systems in office buildings. Applied Energy, Volume 245, Number; 65–77
- Li, A., Xiao, F., Zhang, C., Fan, C., 2021, Attention-based interpretable neural network for building cooling load prediction. Applied Energy, Volume 299, Number; 117238
- Serale, G., Fiorentini, M., Capozzoli, A., Bernardini, D., Bemporad, A., 2018, Model Predictive Control (MPC) for Enhancing Building and HVAC System Energy Efficiency: Problem Formulation, Applications and Opportunities. Energies, Volume 11, Number 3; 631
- Seyedzadeh, S., Rahimian, F.P., Glesk, I., Roper, M., 2018, Machine learning for estimation of building energy consumption and performance: a review. Visualization in Engineering, Volume 6, Number 1; 5
- Tien, P.W., Wei, S., Darkwa, J., Wood, C., Calautit, J.K., 2022, Machine Learning and Deep Learning Methods for Enhancing Building Energy Efficiency and Indoor Environmental Quality – A Review. Energy and AI, Volume 10, Number; 100198
- Yang, S., Wan, M.P., Chen, W., Ng, B.F., Dubey, S., 2020, Model predictive control with adaptive machine-learning-based model for building energy efficiency and comfort optimization. Applied Energy, Volume 271, Number; 115147
- Yu, J., Chang, W.-S., Dong, Y., 2022, Building Energy Prediction Models and Related Uncertainties: A Review. Buildings, Volume 12, Number 8; 1284
- Zhao, R., Wei, D., Ran, Y., Zhou, G., Jia, Y., Zhu, S., He, Y., 2022, Building Cooling load prediction based on LightGBM. IFAC-PapersOnLine, Volume 55, Number 11; 114–119

1. Erstbegutachter Name und Unterschrift:

Schneider Simon MSc.



2. Zweitbegutachter Name und Unterschrift:

DI Sengl David



Digital signiert von David Sengl
DN: cn=David Sengl, c=AT, o=FIH
Technikum Wien, ou=Climate Fit
Building Technologies,
email=David.Sengl@technikum-wien.at
Datum: 2023.02.02 08:28:40 +01'00'